

1. Experiment Central: Divergenta Politicilor

- a) Deși Q-Learning învata calea mai eficientă, are nevoie de mai multă antrenare și per total SARSA obține suma cumulativă mai mare deoarece alege varianta mai safe de descoperire a drumului, astfel nu risca mai mult decât este necesar.
- b) Cei doi algoritmi converg către politici diferite datorită modului în care calculează următoarea alegere a acțiunii. Q-Learning este un algoritm off-policy, se bazează strict pe găsirea acțiunii optime pentru următoarea stare. Presupune că nimic rău nu s-ar putea întâmpla și alege să ignore această șansă de 10% de a explora aleatoriu (care poate duce la prăpastie). În schimb, SARSA este un algoritm on-policy. Următoarea acțiune este calculată ținând cont de probabilitatea ca aceasta să fie una random. Pentru a evita căderea în prăpastie și penalizarea gravă, alege un drum mai sigur evitând cât de mult zona de pericol.
- c) Nu există nicio contradicție deoarece la final politica este evaluată presupunând o execuție perfectă ($\epsilon = 0$), la care se poate ajunge după mai multe epoci de antrenare. Q-Learning insistă pe varianta optimă până când reușește să o parcurgă până la capăt, fără a acționa înspre un câmp de penalizare maximă. SARSA sacrifică calea cea mai optimă pentru siguranță și învata astfel mult mai bine la început, urmând că la un moment dat să se plafoneze.

2. Provocare – reward shaping

Pentru a forța ambii algoritmi să convergă spre aproximativ aceeași politică am modificat recompensa, aplicând o penalizare mai mare (-20 în loc de -1) pentru celulele din apropierea prăpastiei. Astfel obligăm algoritmul de Q-Learning să evite acea zonă optimă de parcurgere pe lângă prăpastie, ca să se apropie de rezultatul obținut prin SARSA. Ambii algoritmi sunt acum de acord în mare parte asupra drumului, la o distanță rezonabilă de prăpastie pentru a evita căderea.

3. Provocare – Epsilon – scheduling

Am implementat o funcție de decalare a epsilon în care rata de explorare scade treptat spre zero în timp. Pe măsură ce epsilon se reduce, probabilitatea ca agentul să se acționeze aleator dispare. În consecință agentul nu mai cade de pe stâncă. Matematic, SARSA începe să se apropie de Q-Learning deoarece acțiunea testată devine acțiunea greedy în 99% din cazuri. Fără riscul de a cădea în prăpastie în timpul antrenamentului, SARSA evaluează corect calea de pe margine ca fiind sigură, determinând alinierea cu algoritmul de Q-Learning.

4. Reflectie teoretica

- 1) Ambii algoritmi nu vor reuși să învețe calea optimă. Cu explorare 0% agentii acționează în mod greedy asupra unui tabel Q format doar din zerouri. Odată ce fac un pas și primesc penalizarea de -1, rămân blocați neștiind ce să facă mai departe.
- 2) Un discount factor sub 1 înseamnă că penalizarile viitoare valorează matematic mai puțin decât cele imediate. Astfel, SARSA va începe să fie mai curajos, penalizarea de -100 va părea încă departe așa că nu va mai ocoli așa mult de frică. Q-Learning va intensifica și mai mult încercarea de găsire a drumului optim în cât mai puțini pași.

3) As prefera SARSA intr-un caz in care antrenarea obiectului presupune siguranta sporita. Daca antrenam un model sa conduca o masina autonom ai prefera sa fie cat de prudent posibil, sa mearga cu 5km/h daca asta garanteaza ca ajunge la destinatie fara incidente. Cu Q-Learning modelul ar merge mai aproape de perete, sau cu viteza mai mare doar pentru a putea ajunge la destinatie mai repede, mai eficient. SARSA se asigura ca evita orice explorare care poate duce la un output negativ.